

面向开放世界概念漂移的 IoT 异常流量检测：低误报阈值校准 与轻量模型修正 (中文写作稿 v0.6)

作者：_____ 单位：_____

2026-01-30

摘要

开放世界部署下，IoT 正常流量会随设备、场景与时间迁移持续漂移，固定于 ID 分布的异常分数与阈值机制在 stronger OOD 正常流量上易出现失稳并引发误报膨胀。本文围绕“低误报可控性”重述研究目标：在保持轻量统计特征前端的前提下，分轨评估历史特征链与 original-frontend 主线，系统考察检测器行为、固定阈值失稳、阈值校准可恢复性与模型层补充修正的相对作用。实验显示，在 original-frontend 100 维 cross-capture 主线上，固定 ID 阈值会显著放大 Transformer 的 OOD 误报；无监督校准可将 Transformer 与 dA 的误报差距压缩到接近水平，表明阈值层是当前主要控制杠杆。在此基础上，本文引入 Tail-Regularized Transformer 作为轻量模型层补充，在多 seed 下稳定缓解 fixed-threshold 敏感性，但在 calibrated 条件下额外收益有限。上述结果支持当前阶段的核心判断：开放世界低误报需要“输入链一致性 + 阈值机制 + 轻量模型修正”的联合设计。

关键词：开放世界；概念漂移；异常流量检测；低误报；阈值校准；尾部正则

1 引言

真实网络中的 IoT 异常流量检测并不处于封闭测试集条件，而是长期运行在开放世界环境：新设备接入、固件升级、业务行为切换与网络策略调整会持续改变正常流量分布。该变化并非偶发扰动，而是部署过程中的常态。许多方法在单域 benchmark 上可取得较高分数，但一旦跨设备、跨场景或跨时间段迁移，误报率往往快速上升，直接削弱告警系统在运维侧的可用性与可信性。

现有主流范式多以重构误差刻画“偏离正常性”，并在单域训练后使用静态阈值进行报警。该范式隐含正常分布相对稳定的假设，与开放世界下的概念漂移存在结构性冲突：未知正常流量进入部署域后，同样可能触发高重构误差，从而造成误报失控。进一步地，单纯 model swapping（例如仅替换编码器结构）通常只能改变局部拟合能力，难以回答核心研究问题：模型在未知环境中是否仍能维持低误报且稳定检测。当前文献对低误报目标、不确定性校准与跨域泛化之间关系的系统讨论仍然不足。

针对上述问题，本文不再将研究简化为“替换一个更强检测器”，而是围绕开放世界低误报开展分层分析：在保持轻量统计特征前端的前提下，区分历史输入链与 original-frontend 主线，依次考察 detector 行为、fixed-threshold 失稳与无监督校准可恢复性，并进一步评估面向正常分数上尾的轻量模型层修正（TailReg）在 stronger OOD 下的补充价值。

更关键的是，我们在固定 stage1 protocol 下完成了 3-seed 稳定性复验，并同时考察 Transformer backend 与原版 dA/KitNET baseline 在两类 OOD benign 流量（IoT-23 benign、CICIoT2023 benign）上的行为。在每个 OOD 数据上，2 个检测器 $\times$ 3 个 seeds 的 6 次运行均出现告警比例 1.0。该结果表明，问题并非单一检测器的偶然失效，而是现有检测链在开放世界条件下面对跨域正常流量时存在共性脆弱性：基于 ID 域校准的固定阈值在新域 benign 输入上可整体失效，进而触发稳定且严重的误报爆炸。本文据此将关注点明确放在低误报可控性与跨域稳健性，而非单域分数提升。

进一步地，在 original-frontend 100 维 stronger OOD 主线上，误报行为呈现清晰层次：同-capture 分段下告警较低，而 cross-capture 条件下固定阈值误报显著放大。多 seed 结果显示，未校准时 detector 间差异会被阈值失配放大；经无监督 OOD 校准后差距快速收敛，说明阈值层是主要杠杆。基于这一机制判断，本文将 TailReg 定位为模型层补充修正：主要缓解 fixed-threshold 脆弱性，而非替代校准的终局方案。

基于这一思路，本文将研究重点从“单域 Mirai 上的精度优化”转向“开放世界条件下的鲁棒异常流量检测”。我们不将方法价值建立在一次性涨点上，而是强调在概念漂移与未知正常流量持续出现时，检测器能否保持低误报、可校准与可迁移。本文贡献如下：

- **问题定义贡献：** 本文将 IoT 异常流量检测形式化为开放世界设定下的低误报风险控制问题，并明确输入链分轨角色：dirty116 仅作历史污染对照，clean115 主要用于历史 CSV 链 detector 比较，original-frontend 100 维承载当前 stronger OOD 主线结论。
- **方法补充贡献：** 在 Transformer 检测器与阈值校准分析基础上，进一步引入 TailReg 作为轻量模型层修正，针对正常分数上尾过高导致的 fixed-threshold 敏感性进行补强；其定位是补充机制，而非替代阈值层校准的终局方案。
- **评测协议与证据贡献：** 构建分层评测口径：历史单域 AUC/PR-AUC 用于回溯 detector 表现，original-frontend stronger OOD 主线重点报告同-capture 与 cross-capture 的误报分层，以及 fixed 与 calibrated 条件下的 OOD 告警比例。阶段性证据表明，本文不仅揭示了 stronger OOD 下 fixed-threshold 误报放大与阈值迁移问题，也表明面向正常分数上尾的轻量模型层修正可稳定缓解未校准场景中的误报敏感性。

1.1 问题陈述 (Problem Statement)

给定由轻量统计特征前端构造的流量样本（向量或序列），模型输出异常分数并在开放世界条件下完成低误报检测。本文采用输入链分轨设定：dirty116 仅作历史污染对照，clean115 用于历史

CSV 链 detector 比较, original-frontend 100 维用于 stronger OOD 主线评测与方法验证。该问题面临四项核心挑战: 其一, 概念漂移导致“训练时正常”与“部署时正常”偏离; 其二, 未知正常性使异常分数与阈值边界随时间移动; 其三, 输入链不一致会放大跨域误报并干扰 detector 比较; 其四, 缺乏阈值迁移与模型层补偿机制会使低误报目标难以稳定落地。本文方法与评测均围绕上述挑战展开。

1.2 开放世界失稳的预备性观察

为验证问题是否真实存在, 本文先进行面向问题定义的预备性跨域核验, 而非将其作为最终正式跨域主实验。我们固定 stage1 配置, 采用 3-seed 重复设置, 对 Transformer backend 与原版 dA/KitNET baseline 进行并行对照, 并在 IoT-23 benign 与 CICIOT2023 benign 两类 OOD 正常流量上观察告警行为。

结果呈现出高度一致性: 在两类 OOD benign 输入上, 两个检测器在 3 个随机种子下均出现告警比例 1.0 的稳定现象。该现象说明, 当部署侧正常性发生跨域漂移时, 现有检测链中的分数与固定阈值机制会出现系统性失配, 进而导致误报失控。需要强调的是, 当前 OOD 输入仍基于 adapter 映射后的 116 维表示, 因此这些结果更适合作为问题动机与跨域现象证据, 而非对“真实开放世界下必然 100% 误报”的最终定稿级结论。

2 背景与问题定义

2.1 KitNET 管线概述

KitNET 以固定特征映射为输入, 利用一组子自编码器分别处理特征簇, 再将各子模型的重构误差输入到输出自编码器, 最终以重构误差 (或其聚合) 作为异常分数。

2.2 训练/评估阶段与 grace 对齐

为了避免训练阶段与评估阶段的混淆, 本文采用三段式口径: 特征映射学习阶段 (FMgrace = 5000)、检测器训练阶段 (ADgrace = 95000)、执行期评估阶段。定义

$$\text{exec_start} = \text{FMgrace} + \text{ADgrace} + 1 = 100001, \quad (1)$$

仅在 $t \geq \text{exec_start}$ 的样本上计算 AUC/PR-AUC。

2.3 任务定义

给定分轨输入特征 (clean115 历史比较链与 original-frontend 100 维主线) 及其标签或评估切片, 模型输出每条样本的异常分数。在历史单域窗口上报告 ROC-AUC/PR-AUC, 在开放世界主

线上额外报告 fixed 与 calibrated 条件下的 OOD 告警比例。

3 方法

3.1 总体思路

本文从轻量统计特征前端出发，围绕开放世界低误报问题依次考察三类机制：检测器替换、阈值校准，以及面向正常分数上尾的轻量模型层修正。具体实现中，我们保持与 KitNET 兼容的重构式评分接口，并在不同输入链与协议下比较各机制对误报可控性的贡献。

3.2 输入表示（特征序列化）

在本文实现中，Transformer 的“序列”不是时间窗口，而是特征维度本身。对每个子模型，其输入向量维度记为 input_dim （即该特征簇的维度）。我们将 input_dim 维向量视作长度 $T = \text{input_dim}$ 的序列，每个 token 对应一个特征分量。该设计使得自注意力直接在特征维度上建模全局依赖。

3.3 Transformer 检测器结构

我们采用 encoder-only 结构（Transformer Encoder）。层数 $L = 1$ ，注意力头数 $H = 4$ 。隐藏维度 d_{model} 依据输入维度自适应设置：

$$d = \max(8, \min(128, \text{input_dim})), \quad (2)$$

并调整为可被 H 整除。前馈网络维度

$$\text{dim_feedforward} = \max(32, d, \lfloor d \cdot 4 \cdot \text{hidden_ratio} \rfloor). \quad (3)$$

为对齐对比，本实验设置 $\text{dropout} = 0.0$ 。

3.4 Tail-Regularized Transformer（阶段性方法补充）

在 original-frontend 100 维的 stronger OOD cross-capture 设置下，我们观察到 baseline Transformer 在固定 ID $q99$ 阈值时对正常分数上尾更敏感，导致 fixed-threshold 误报波动与抬升。针对这一短板，本文在不改变主干结构与推理流程的前提下引入 TailReg：在训练目标中增加面向正常分数上尾的轻量约束，以抑制尾部过高样本对固定阈值的放大效应。

具体实现上，TailReg 保持重构主损失与推理接口不变，仅在训练阶段对正常分数上尾施加轻量软约束。本轮稳定性实验采用固定 best configuration ($\lambda = 0.2$, $k = 1.0$, $\text{warmup} = 256$, $\text{ema_alpha} = 0.01$)。该修正的角色定位为模型层补充，用于改善 fixed-threshold 脆弱性，而非替代阈值层校准机制。

3.5 训练目标与异常分数

为与原版 KitNET 保持一致，我们采用重构式训练目标：模型输入为特征 token 序列，输出为对输入特征的重构，以均方误差（MSELoss）作为训练损失。推理时，我们以重构误差的均方根（RMSE）作为异常分数，并加入极小常数避免数值为零：

$$\text{mse}(\mathbf{x}, \hat{\mathbf{x}}) = \text{mean}((\mathbf{x} - \hat{\mathbf{x}})^2), \quad (4)$$

$$\text{rmse}(\mathbf{x}, \hat{\mathbf{x}}) = \sqrt{\text{mse}(\mathbf{x}, \hat{\mathbf{x}})}, \quad (5)$$

$$\text{score}(\mathbf{x}) = \text{rmse}(\mathbf{x}, \hat{\mathbf{x}}) + 10^{-6}. \quad (6)$$

其中 $\mathbf{x}$ 为输入特征向量， $\hat{\mathbf{x}}$ 为模型重构。所有 ROC-AUC 与 PR-AUC 均仅在执行期窗口 ($t \geq \text{exec_start}$) 上计算。

上述重构评分流程可在不同输入链复用；算法 1 给出 clean115 历史链的阶段划分示例，original-frontend 100 维主线沿用同一执行期评分逻辑并替换对应协议切片。

3.6 与原版 KitNET 的关系（控制变量说明）

本文并非单一“保持特征不变，只换检测器”的设置。在历史 clean115 链上，我们主要控制变量比较 detector 的表达差异；在 original-frontend 100 维 stronger OOD 主线上，我们进一步考察 fixed threshold、无监督校准与 TailReg 的联合作用。因此，本文与原版 KitNET 的关系是共享轻量重构接口与阶段划分原则，但结论建立在分轨协议下的机制分析，而非单一路径涨点。

4 实验设置

4.1 数据与 gold 标准

本文按输入链分轨组织数据：dirty116 为历史污染链，仅作参考；clean115 为历史 CSV 清洗链，主要用于 detector 单域比较；original-frontend 100 维为当前开放世界主线，用于 cross-capture stronger OOD 评测。对于历史单域实验，仍使用 Mirai 对齐标签切片（my_gold_mirai.csv / my_gold_labels.npy）以保证与既有结果可比。

4.2 阶段划分与评估窗口（grace 对齐）

历史单域对比采用 grace 对齐口径：FMgrace = 5000、ADgrace = 95000，并在 exec_start = 100001 之后计算执行期 AUC/PR-AUC。original-frontend 100 维主线采用固定 stronger OOD 协议（train_samples=8000, id_eval_samples=5000, fm=2000, ad=6000），并分别在 fixed 与 calibrated 阈值条件下统计 OOD 告警比例。

Algorithm 1: 基于重构误差 (RMSE) 的 KitNET/Transformer 异常检测流程 (含 grace 对齐与执行期评估)

Input: 数据矩阵 $\mathbf{X} \in \mathbb{R}^{N \times d}$ (clean115 历史链示例: my_gold_mirai.csv, $N = 200\,000$); 标签 $\mathbf{y} \in \{0,1\}^N$ (clean115 历史链示例: my_gold_labels.npy); 阶段参数 FMgrace = 5000, ADgrace = 95000, exec_start = 100001; 检测器 $f(\cdot)$; $\varepsilon = 10^{-6}$.

Output: 执行期异常分数序列 $\{s_t\}_{t=\text{exec_start}}^N$; 评价指标: ROC-AUC 与 PR-AUC (仅在执行期计算)

```

// Gold 构造 (离线准备)
1 运行 prepare_gold_data.py (clean115 历史链示例), 从官方 Mirai_dataset.csv 与
   mirai_labels.csv 同步截取前 200 000 行, 生成 my_gold_mirai.csv 与
   my_gold_labels.npy.;
// 阶段划分 (严格对齐)
2 特征映射学习阶段  $t \in [1, \text{FMgrace}]$ ; 检测器训练阶段
    $t \in [\text{FMgrace} + 1, \text{FMgrace} + \text{ADgrace}]$ ; 执行期评估阶段  $t \in [\text{exec\_start}, N]$ .;
// 训练
3 使用训练阶段样本对检测器进行无监督重构训练, 最小化 MSELoss.;
// 推理与评分 (仅执行期)
4 for  $t \leftarrow \text{exec\_start}$  to  $N$  do
5    $\hat{\mathbf{x}}_t \leftarrow f(\mathbf{x}_t)$ ;
6    $s_t \leftarrow \text{RMSE}(\mathbf{x}_t, \hat{\mathbf{x}}_t) + \varepsilon$ ;
// 评价
7 在执行期窗口上用  $\{(s_t, y_t)\}$  计算 ROC-AUC 与 PR-AUC, 并保存到
   runs/auc.txt.;

```

4.3 对比方法与公平性约束

对比方法包含 dA/KitNET、Transformer 与 Transformer_tailreg。历史单域链主要用于 dA 与 Transformer 的回溯比较; original-frontend 主线进一步加入 Transformer_tailreg 以检验模型层修正的补充作用。为保证公平对比, 同一协议内各方法共享相同数据切片、阶段配置与评估口径。

4.4 指标

本文采用分层指标口径: 历史单域链报告执行期 ROC-AUC 与 PR-AUC; original-frontend stronger OOD 主线重点报告 fixed OOD alarm ratio 与 calibrated OOD alarm ratio (含预算与目标误报约束), 用于直接刻画低误报可控性。

表 1: 历史特征链上的单域对比结果 (执行期评估窗口)

方法	ROC-AUC	PR-AUC	运行实例
Baseline: 原版 KitNET (AE + Output AE)	0.990 331	0.997 515	runs/4717/auc.txt
Ours: Transformer 检测器	0.999 917	0.999 976	runs/4718/auc.txt
提升 (Ours – Baseline)	0.009 586	0.002 461	—

4.5 可复现性与输出规范

实验通过 Slurm 作业提交执行, 结果按 runs/<id>/ 目录保存, 包含指标文件与日志。历史单域对比结果对应 runs/4717 (baseline) 与 runs/4718 (Transformer); original-frontend stronger OOD 与 TailReg 稳定性结果按协议汇总为多 seed 聚合统计。(注: 建议后续统一以 jobid/run_tag 命名, 避免覆盖并便于汇总。)

5 主结果

5.1 历史单域对比结果 (历史特征链)

5.2 结果解读

表 1 给出历史特征链上的单域对比结果, 可用于回溯 detector 在受控执行期窗口中的排序能力差异。该结果说明在历史链上 Transformer 具备较强单域拟合能力, 但其定位是背景性对照证据, 不构成本文开放世界 stronger OOD 主线的结论依据。进一步地, 该表主要用于说明历史链上的 detector 排序能力差异, 不用于支持本文关于开放世界 stronger OOD 低误报机制的核心结论。下面转入 original-frontend 主线上的误报机制分析。

5.3 stronger OOD 现象与阈值机制分析

在同一 original-frontend 100 维输入链下, 协议强度提升会带来明显误报分层: 同-capture 分段 (较弱 OOD) 下, OOD 告警比例较低 (Transformer: 0.00610, dA: 0.01085); 切换到 cross-capture (stronger OOD) 后, seed=42 stage1 下分别升至 0.44175 与 0.12580。该现象说明, 开放世界误报问题在 stronger OOD 条件下会被显著激活, 且需要在主线协议中单独分析。

在固定 cross-capture 协议 (seed=101/202/303) 上, 我们进一步比较 fixed threshold 与 calibration 两种阈值策略, 如图 1 所示。

作为图 1 与图 2 的数字摘要, 表 2 仅用于快速对齐关键读数。结合图 1 可见, fixed 条件下 Transformer 与 dA 的平均误报差距为 0.316983; 在无监督 OOD calibration (budget=5000, target=1%) 后, 差距降至 0.000333, 收缩约 99.9%。该结果说明, fixed threshold 会显著放大




图 1: original-frontend stronger OOD 主线中 fixed 与 calibrated 的告警比例对比: 校准后 detector gap 显著收缩。

表 2: 主线核心数字的紧凑摘要 (mean $\pm$ std): 服务于图 1与图 2的读数锚定。

检测器	Fixed OOD alarm ratio (mean $\pm$ std)	Calibrated OOD alarm ratio (mean $\pm$ std)
Transformer	0.4548 $\pm$ 0.2769	0.01549 $\pm$ 0.00068
Transformer_tailreg	0.1393 $\pm$ 0.0911	0.01549 $\pm$ 0.00068
dA/KitNET	0.1378 $\pm$ 0.0050	0.01516 $\pm$ 0.00003

stronger OOD 误报, 而 calibration 是当前低误报控制的主要杠杆; 因此 detector 间在未校准场景中的大部分表现差异更应解释为阈值迁移问题, 而非模型本体优劣。

因此, 当前更稳妥的结论是阶段性稳定结论: 阈值层是 stronger OOD 低误报控制的关键杠杆, 且检测器表现与 threshold mechanism 强耦合; 同时, 校准后仍存在 residual gap, 说明分数建模与输入链一致性仍然重要。需要强调边界条件: 现有 stronger OOD 结果基于特定 benign cross-capture 组合, 尚不足以外推为终局结论。

5.4 尾部正则对 stronger OOD 固定阈值敏感性的影响

前述分析表明, stronger OOD 条件下固定阈值机制会放大 Transformer 的误报敏感性。基于这一现象, 我们进一步检验模型层最小修正是否能够在不改变协议前提下改善 fixed-threshold 行




图 2: TailReg 与基线在 stronger OOD 主线下的对比：其显著收益主要出现在 fixed-threshold 条件，calibrated 条件下额外收益有限。

为，即在同一 original-frontend 100 维、同一 cross-capture 设置下引入 TailReg，并与 baseline Transformer、dA 进行多 seed 对照。

结合图 2 与表 2，多 seed 聚合结果显示：fixed OOD alarm ratio 上，Transformer 为 0.4548 ± 0.2769 ，Transformer_tailreg 为 0.1393 ± 0.0911 ，dA 为 0.1378 ± 0.0050 ；在 calibrated OOD alarm ratio (budget=5000, target=1%) 下，Transformer 与 Transformer_tailreg 均为 0.01549 ± 0.00068 ，dA 为 0.01516 ± 0.00003 。相对 baseline Transformer，TailReg 在 fixed-threshold 条件下的平均绝对下降为 0.31545，相对下降为 69.36%。

这些结果支持如下阶段性解释：TailReg 的主要贡献是稳定改善 fixed-threshold 场景中的误报敏感性。TailReg 在 fixed-threshold 下已将 Transformer 的 stronger OOD 误报压到接近 dA 的量级，而 calibration 进一步说明 detector 间的大部分表观差异来自阈值迁移而非模型本体；同时，TailReg 在 calibrated 条件下额外收益有限。由此可见，阈值层仍是当前低误报控制的主要杠杆，TailReg 更适合作为模型层补充机制；现有证据仍局限于当前 benign cross-capture 组合，尚不能外推为终局结论。

6 后续计划

- **强基线对比：**在 clean115 与 original-frontend 100 维两条输入链下补充 Isolation Forest、LOF、One-Class SVM、AE/LSTM-AE/TCN-AE 等。

- **消融实验**: $L/H/d$ 、是否位置编码、归一化策略、`hidden_ratio` 等。
- **鲁棒性**: `grace` 参数敏感性、多随机种子均值 $\pm$ 方差。
- **效率**: 训练时间、推理吞吐、显存/内存占用。